Úvod do vyhľadávania informácií základné problémy a pojmy

Vyhľadávanie informácií

Mgr. Martin Šeleng, PhD.
Ústav Informatiky SAV
Dúbravská cesta 9, Bratislava
miestnosť č. 312

Podmienky

Získanie zápočtu = získanie minimálne 25 bodov (50%) počas semestra z 50 bodov:

- **odovzdanie a odprezentovanie praktických projektových zadaní (30 bodov).**
- **priebežná práca = aktívne konzultovanie projektov aspoň 5 krát za semester (aktívna účasť na konzultáciách - predpokladá sa príprava študenta a prezentovanie progresu) v rámci cvičení (20 bodov), kde je potrebné byť pripravený.**

Vykonanie záverečnej skúšky (50 bodov – minimum 25 bodov – 50%)

Získanie aspoň 56% celkového hodnotenia (56 bodov).

Aktívna účasť na konzultáciách (predpokladá sa príprava študenta a prezentovanie progresu)
- Zadanie 1 – minimálne 3 konzultácie
- Zadanie 2 – minimálne 3 konzultácie

Vypracovanie a odovzdanie všetkých zadaní s minimálnou úrovňou kvality v stanovených termínoch + osobne na konzultácii.

Získanie aspoň 25 bodov (z možných 50) za zadania v priebehu semestra (Z1 20b, Z2 30b)
Získanie aspoň 56 bodov z celkového hodnotenia (zadania max 50 + 10 bonus, skúška 50)

Podmienky – konzultácie (1)

- priebežná práca – aktívne konzultovanie projektov aspoň 6-krát za semester v rámci cvičení (20 bodov) – projekt (30 bodov)
- 1. konzultácia – výber a potvrdenie projektu + dáta
  - Opis projektu - stručný prehľad (TLDR) + motivácia.
  - Odkaz na stránky, ktoré idete scrapovať + aké dáta sú pre vás zaujímavé.
  - Odkaz na wiki stránky, ktoré budete pripájať k vašim dátam + aké dáta sú pre vás zaujímavé.
  - Minimálne 5 párov otázok a odpovedí, aké si predstavujete, že má váš systém bude prijímať a čo má "odpovedať".
- 2a. konzultácia – návrh riešenia (jednoduchý pseudokód)
  - Aké frameworky chcete používať?
  - Diagram architektúry vášho crawl systému (ukážka).
  - Aké hlavičky používate, aký timeout/sleep?
  - Implementácia crawlera + zopár už stiahnutých stránok.
- 2b. konzultácia
  - Dokončený crawler.
  - Stiahnuté všetky dáta + štatistika (počet, veľkosť na disku).
  - Dokončený extraktor (REGEX) + ukážky na wiki.
  - Vlastný indexer, minimálne 2 metódy výpočtu "idf" – ranku výsledkov.
  - BONUS: Jednoduché unit testy (aspoň na 20 stránkach) na vaše REGEX extraktory.
  - BONUS: Pridať do štatistiky aj počet tokenov tiktoken

Podmienky – konzultácie (2)

- Odovzdanie prvej časti projektu
  - Odovzdanie má byť vo forme “reportu”, kde musíte stručne opísať, čo ste robili, a stručne okomentovať každý bod odovzdania. Čo nie je na wiki, nebude hodnotené.
  - Kapitoly/Sekcie, ktoré musí obsahovať odovzdanie
    - **Opis projektu, čo je cieľom.**
    - **Odkaz na stránky, ktoré ste scrapovali + aké dáta ste extrahovali (5 ukážok).**
    - **Minimálne 5 párov otázok a odpovedí, aké si predstavujete, že váš systém bude prijímať a čo má odpovedať.**
    - **Aké frameworky a knižnice ste použili a prečo.**
    - **Architektúra vášho crawlovacieho systému, vrátane diagramu.**
    - **Tabuľka s ukážkou vašich metadát, ktoré si ukladáte pri crawlovaní - ak si neukladáte metadáta tak dôvod.**
    - **Odôvodnenie použitých hlavičiek, timeoutov, sleepov**
    - **Ukážka vášho reálneho (nie pseudokódu) implementovaného kódu na extrakciu URL z HTML + ideálne aj preklik do reálneho kódu**
    - **Ukážka vášho reálneho (nie pseudokódu) implementovaného kódu na extrakciu entít z HTML/text/md + ideálne aj preklik do reálneho kódu**
    - **Opis vami vytvoreného indexera a INDEXU (TF), koľko krát ho vytvárate etc.**
    - **Opis vami implementovaných metód výpočtu “idf”**
    - **Ukážka porovnania správania jednotlivých metód výpočtu “idf” na aspoň 3 vstupných dopytoch (queries)**
    - **Tabuľka so štatistikou vami vycrawlovaných dokumentov - počet, veľkosť na disku, koľko z nich je relevantných pre váš projekt.**
    - **ZIP súbor s kódom**
    - **BONUS: Súbor so všetkými unit testami na vaše REGEX extraktory.**
    - **BONUS: Doplnenie štatistiky o počet tokenov**

Podmienky – konzultácie (3)

- 3. konzultácia – Spracovanie "veľkých" dát
  - Rozšíriť kód z prveho odovzdania na spracovani dát, prechod na distribuované spracovanie (Apache Spark).
  - Extrahovať a spracovať dáta (vrátane wiki dumpu) pomocou Sparku.
  - Práca s wiki dátami (pomocou REGEX-ov).
  - Odôvodniť a ukázať “join” medzi vami extrahovanými dátami a dátami z wiki.
  - Koľko unikátnych wiki stránok ste pripojili.
  - Aké atribúty z wiki sú pre vás zaujímavé.
- 4. konzultácia – Lucene index
  - Hotový Spark kód (wiki, extrahované dáta, join)
  - Návrh a implementácia indexu pomocou PyLucene
  - Odôvodnenie jednotlivých polí (fields) v indexe
  - Implementácia nového indexu do vašej aplikácie
  - Porovnanie dopytov (queries): starý index vs. nový index
  - Aké typy dopytov (queries) v indexe využívate (napr. Boolean – AND/OR, Range, Phrase, Fuzzy)?
  - ODKAZ NA GITHUB (s vašim aktuálnym kódom)
- 5. konzultácia – Evaluácia
  - Hotový softvér (aj na GitHube) + prezentovanie výsledného riešenia
  - Vyhodnotenie výsledkov vyhľadávania
  - Porovnanie vašich výsledkov s vyhľadávaním na Google a na doméne, ktorú ste crawlovali.
  - Výsledky prezentované v textovej podobe (nie ako obrázky).

Podmienky – konzultácie (4)

- Odovzdanie druhej časti projektu
  - Architektúra distribuovaného spracovania (Apache Spark):
    - **Stručný opis prechodu na Spark – ako ste rozšírili kód z prvého odovzdania.**
  - Spracovanie Wikipedia Dumpu:
    - **Opis, ako ste extrahovali a čistili dáta z Wiki dumpu.**
  - Integrácia dát (The Join):
    - **Odôvodnenie a logika "joinu": Ako a prečo ste spojili vami crawlované dáta s dátami z Wikipédie.**
    - **Štatistika prepojenia: Koľko unikátnych wiki stránok sa podarilo pripojiť k vašim dátam.**
    - **Zoznam atribútov z Wikipédie, ktoré ste sa rozhodli indexovať, a prečo sú pre váš projekt zaujímavé.**
  - Indexovanie (PyLucene):
    - **Návrh schémy indexu: Zoznam všetkých polí (fields), ktoré indexujete.**
    - **Odôvodnenie jednotlivých polí a ich typu.**
    - **Aké typy dopytov (queries) využívate?**
  - Vyhodnotenie a porovnanie:
    - **Starý vs. Nový index: Porovnanie výsledkov vyhľadávania (kvalita, rýchlosť, relevantnosť) medzi vaším riešením z 1. odovzdania a aktuálnym PyLucene riešením.**
    - **Vaše riešenie vs. Google/Doména: Porovnanie vašich výsledkov s vyhľadávaním na Google (resp. search barom na crawlovanej doméne) pre aspoň 5 rôznych dopytov. Výsledky prezentujte v prehľadnej tabuľke (textová podoba, nie screenshoty).**
  - Odkaz na GitHub:
    - **ODKAZ NA GITHUB a ZIP súbor s kódom**

Podmienky – konzultácie (5)

- 1. konzultácia – výber a potvrdenie projektu
  - **Do 30.09.2026**
- 2. konzultácia – návrh riešenia (jednoduchý pseudokód)
  - **Do 14.10.2026**
- Následne predvedenie – prvého riešenia (funkčná extrakcia, vlastný indexer – neriešiť lematizáciu, vlastný vyhľadávač, implementácia rôznych metrík!!! – aspoň 2 rôzne probability IDF je zakázané) na vzorke dát
  - **Do 28.10.2026**
- 3. konzultácia – rozšírený kód z prvého riešenia (ide hlavne o extrakciu) na väčších dátach Apache Spark
  - **Do 11.11.2026**
- 4. konzultácia - takmer naprogramované riešenie Apache Lucene
  - **Do 25.11.2026**
- 5. konzultácia - hotový softvér, ak dobré je možné aj priamo odovzdať (najlepšie samozrejme na cvičení) s predvedením
  - **Do 09.12.2026**
- odovzdanie projektu – hard deadline
  - **Na poslednej prednáške a cvičeniach do 09.12.2025**

Projekty

- Odovzdať
  - **Software na poslednej prednáške a cvičení**
    - Zavesiť na web na vyskúšanie s popisom ako spustiť
  - **Text na wiki – hlavné linky a max 1 strana.**
    - Čo: Idea
    - Ako: postup, literatúra
    - Overenie: porovnanie výsledkov recall, precission
    - Záver

- Všetko s projektami a konzultáciami (všetky možné body) sa rieši cez wiki a osobné konzultácie (primárne). Čo nie je na wiki neexistuje!
- Nerozpisujte sa príliš.
- V minulosti bol väčší dôraz na text na Wiki, teraz hlavne kód:
  - **zrozumiteľné komenty – v angličtine aj premenné aj komenty**
  - **Unit testy na vzorke dát (Python, Java)**

Podmienky pre úspešné odovzdanie projektu

- Krátke info na wiki (max 1 strana)
  - **krátky popis projektu-problému a motivácia načo je to dobré**
  - **vyhodnotenie slovné subjektívne na nejakých konkrétnych príkladoch. Vo väčšine projektov aj vyhodnotenie pomocou presnosti a úplnosti(precision a recall)**
  - **spustenie, inštalácia softvéru, použitie softvéru**
  - **Všetko na wiki dva dni pred odovzdaním projektu!**
- Softvér priložený ako zip príloha na wiki stránke. 2-5 min predvedenie softvéru. Pripravte si to tak aby sa s tým nezabilo 30 minút. Softvér musí byť pripravený tak aby ho nebol problém spustiť alebo nainštalovať.
- wiki stránka sa myslí stránka vášho projektu

Témy

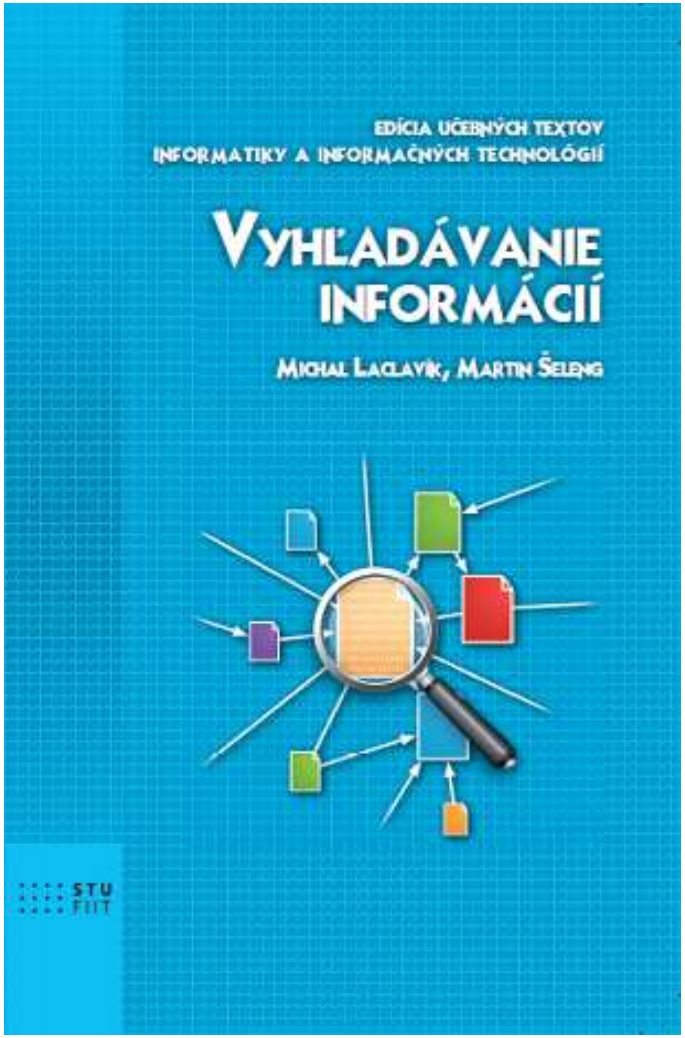
- Textové operácie
- Sťahovanie dokumentov, spracovanie odkazov, tvorba bázy dokumentov
- Indexovanie (Modely)
- Softvérové knižnice a systémy
- Extrakcia informácií
- Vyhľadávanie a usporiadanie
- Regulárne výrazy a ich použitie pri spracovaní textu
- Problém spracovania veľkého množstva dát (MapReduce, Hadoop, Spark, Kaffka, ...)
- Hodnotenie úspešnosti
- Google
- Sémantické vyhľadávanie a sémantické siete
- Úvod - klasifikácia a zhlukovanie na distribuovaných architektúrach?
- Sumarizácia učiva a priblíženie obsahu skúšky

Literatúra

- Michal Laclavík, Martin Šeleng: Vyhľadávanie informácií, 2012
- Steven Bird, Ewan Klein, and Edward Loper: Natural Language Processing with Python, 2009
- Christopher D. Manning, Prabhakar Raghavan and Hinrich Schütze: Introduction to Information Retrieval, Cambridge University Press. 2008
- Ricardo Baeza-Yates, Berthier Ribeiro-Neto: Modern Information Retrieval. Addison Wesley, ACM, 1999
- Singhal, Amit (2001). Modern Information Retrieval: A Brief Overview. Bulletin of the IEEE Computer Society Technical Committee on Data Engineering 24 (4): 35-43
- S Brin, L Page: The anatomy of a large-scale hypertextual Web search engine; Computer Networks and ISDN Systems, 1998
- Michael McCandless, Erik Hatcher, and Otis Gospodnetić: Lucene in Action, Second Edition; Manning Publication; ISBN: 1933988177, 2010
- Apache Lucene - Java based indexing and search library
- Nutch - web search software
- Hadoop - Proceesing vast amount of data
  - Jeffrey Dean, Sanjay Ghemawat: MapReduce: Simplified Data Processing on Large Clusters, Google, Inc. OSDI'04, San Francisco, CA, December, 2004
  - HadoopMapReduce
  - Hadoop Distributed File System
- Jena RDF tutorial
- Text REtrieval Conference (TREC)
- Graphs in IR

Literatúra - Vyhľadávanie informácií

- Vysokoškolská učebnica Vyhľadávanie informácií (Information Reterieval)
- **Názov:**Vyhľadávanie informácií
- **Autori:**Michal Laclavík, Martin Šeleng
- **Vydala:**Slovenská technická univerzita v Bratislave, vo Vydavateľstve STU, Bratislava, Vazovova 5.
- **ISBN:**978-80-227-3829-3
- **Rok vydania:**2012



Všetky informácie o predmete

http://vi2026.ui.sav.sk/

Aplikácie

- Vyhľadávanie – ako na Google
- Sémantické vyhľadávanie (Entity search)
  - **Google knowledge graph**
  - **Wikipedia**
  - **Freebase**
  - **Facebook search**
  - **MAG – Microsoft Academy Graph**
  - **...**
- Linked Data
- Text Analysis, Text Mining

- Žiadaná profesia: Data Scientist

História

- Knižnice
  - Knihy
  - Tvorba indexov
  - Hierarchické zoznamy
  - Prvé IR systémy fungovali v knižniciach
- Cranfield experiment
  - Cranfield University 60 roky, evaluácia efektivity indexovacích systémov (v knižniciach, nie počítačových).
  - Záverom sa zistilo, že metodológia je menej dôležitá ako detaily implementácie, čo viedlo k veľkej diskusii o metodológii týchto experimentov.
- Nástup počítačov, TREC, GOV2
- Internet
  - Katalogizácia, hierarchia (DMoz)
  - Indexovanie web stránok (altavista, MetaCrawler, Yahoo!)
  - Google, PageRank
  - Špecializácia na domény (sémantika)
- Web 2.0, Sociálne siete

História (2)

- 1992, Text REtrieval Conference (TREC)
  - **Poriadaný National Institute of Standards and Technology (NIST)**

- Rôzne tracky na rôzne problémy nielen z webu
  - **Spam**
  - **Blog**
  - **Question Answering**
  - **Entity search**
  - **Filtering stream of new**
  - **News search**
  - **Relevance Feedback**
  - **...**

Internet – nové možnosti a výzvy

- Informácie sú dostupné za oveľa nižšiu cenu
- Informačné zdroje sú distribuované a dostupné veľmi rýchlo a za pár sekúnd
- Sloboda zverejniť akúkoľvek informáciu kýmkoľvek je dostupná prvý krát v histórii
- Dôveryhodnosť informácií – veľký problém

Information Retrieval (1) Ciele

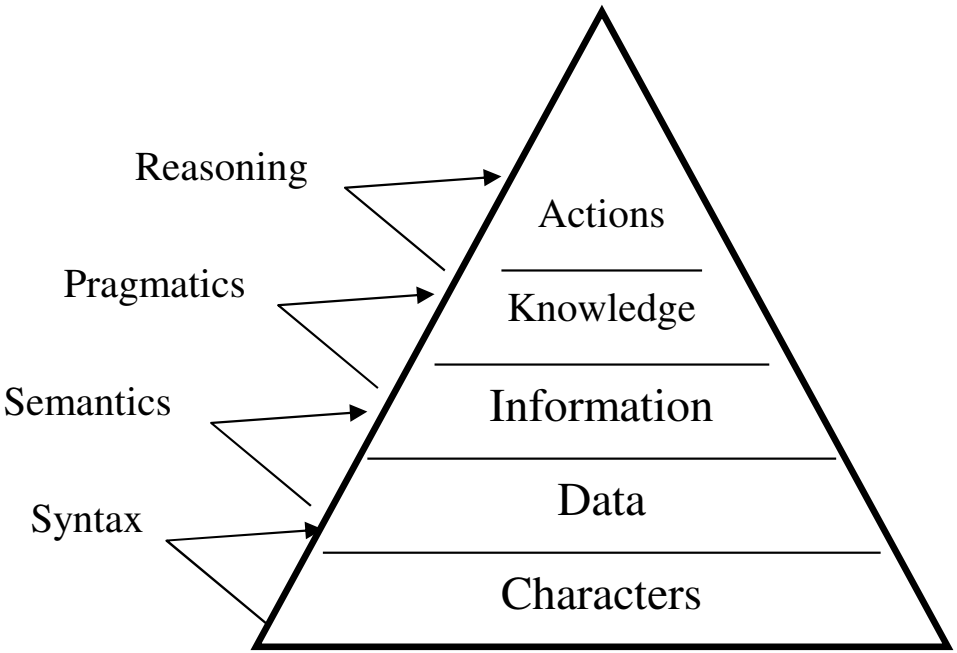
- Reprezentácia
- Uchovávanie
- Organizácia
- Spracovávanie
- Dostupnosť informácií
- Dôveryhodnosť
- Vyhľadávanie

Information Retrieval (2)

- **Dáta:** 20
- **Informácia:** 20 °C
- **Znalosť:** izbová teplota
- **Akcia:** v noci je to veľa, zníž teplotu

- Informácia
  - **Keď dáta majú sémantiku (význam)**

- IR systém nemusí rozumieť sémantike ale je dobré keď sa o to snaží
- Väčšinou štatistický prístup
  - **I v našom prípade pôjdeme viac menej na to štatisticky, ale vo vašich projektoch môžete skúšať čokoľvek**



(Bergman, 2002, Experience Management)

Information Retrieval (3)

- Informácia
  - **Text, dokument**
  - **Obrázky**
  - **Video**
  - **Audio**
- V rámci predmetu VI
  - Primárne text **(dokumenty)**
  - Linky **ako ukazovateľ na iné** objekty
  - Graf **závislosti objektov** (napr. viac dimenzionálne sociálne siete, prepojenie stránok/dokumentov, prepojenie produktov, …)

Information Retrieval

- Klasický prístup
  - Prehľadávanie každého dokumentu a hľadanie reťazcov
  - Časovo náročné
  - Nie nezmyselné
  - Grep, regulárne výrazy, information extraction
- Veľké množstvo dokumentov
  - Potreba indexácie
  - Kľúčové slová (prípadne aj všetky slová dokumentu)
  - Termy
- Dopyt a výsledok
  - Spracovanie dopytu (rozšírenie, zmodifikovanie, ...)
  - Spracovanie výsledku (usporiadanie, vyhodenie, spojenie, ...)

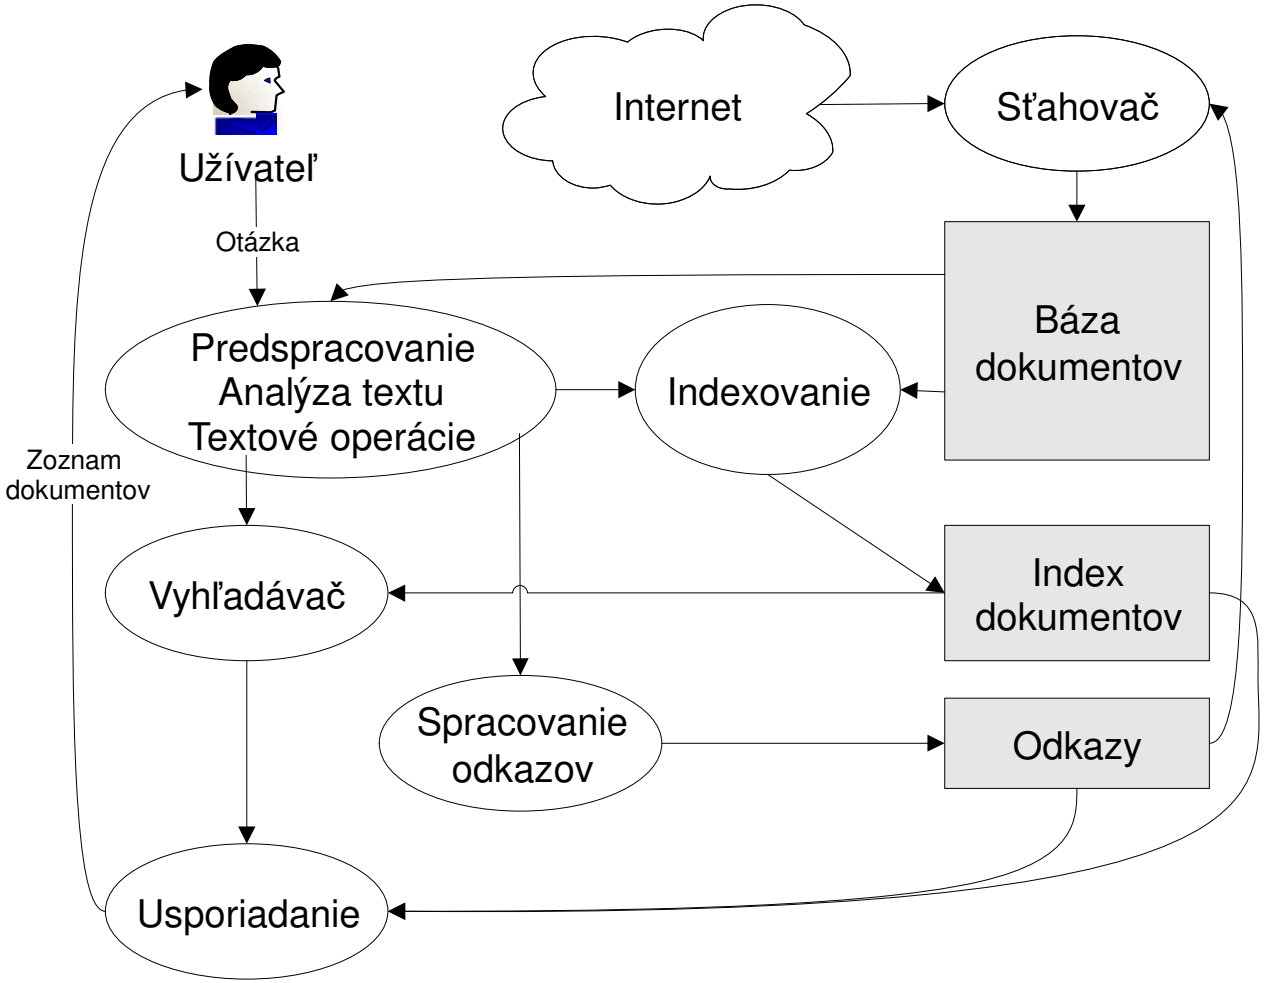
Architektúra

Získavanie informácií

- stiahnutie dokumentov
- textové operácie
- indexovanie
- spracovanie odkazov a objektov v texte

Vyhľadávanie

- formulácia dopytu a operácie na dopyte
- spracovanie dopytu
- vrátenie výsledku na používateľské rozhranie
- spätná väzba od používateľa



Súvisiace témy

- spracovanie prirodzeného jazyka
- grafy a siete
- sémantický web
- kontext používateľa
- vyhľadávanie v multimédiách
- strojový preklad
- škálovateľné IR
- dolovanie v dátach
- business intelligence

Pojmy

- Dokumenty
  - **vlastnosti**
- Textové operácie
  - **Tokenizácia**
  - **Lematizácia, stemming**
- Termy
- Odkazy
- Indexy
- Hodnotenie
  - **Experimentálne overenie**
  - **Recall – pokrytie**
  - **Precision – presnosť**
  - **F1 – kombinácia Recall a Precision**
- Zoraďovanie
  - **URLs, termy, normalizácia**

Pojmy (2) algoritmické, implementačné

- Vector space model
- Booleovský model
- Invertovaný index
- PageRank, HITS, OPIC
- MapReduce

- Google
- Lucene
- Nutch
- Hadoop
- Spark
- Hive
- Kaffka

Témy (1): Indexovanie, modely a miery podobnosti

- Indexy: Jadro systémov pre vyhľadávanie informácií, ktorým je tvorba indexov
- Invertovaný index
- Váhovanie, normalizácia
- Modely
  - **Booleovský**
    - AND, OR, NOT, term sa vyskytuje alebo nie
    - Riedka matica
  - **Vektorový**
    - Vector space model
    - X dimenzionálny priestor, každý term jedna dimenzia
    - Kosínusová miera, medzi 0-1, 1 pre rovnaké dokumenty
    - Podobnosť medzi dopytom a dokumentom
  - **Pravdepodobnostný**
- Miery
  - kosínusová miera
  - euklidovská vzdialenosť
  - Jaccard similarity
  - ...

Témy (2)

- *Sťahovače*
  - **dozviete ako sa získavajú dokumenty z internetu, aké stratégie sťahovania sa používajú, ako sa spracúvajú linky a na čo ich môžeme použiť pre vylepšenie vyhľadávania.**
- *Konverzia dokumentov*
  - **Apache Tika a iné ...**
- *Analýza textu*
  - **Spracovanie textu na termy, tokenizácia, lematizácia, stop slová ...**

Témy (3)

- *Usporiadanie*
  - **Využitie prepojení dokumentov (linky) na výpočet dôveryhodnosti dokumentu ako aj na následné utriedenie výsledkov vyhľadávania.**
- *Hodnotenie*
  - **Pre systémy vyhľadávania informácií je dôležité vyhodnotenie ich úspešnosti. V kapitole sa dozviete aké miery hodnotenia poznáme, ako sa dajú použiť a čo je dôležité pri vyhodnotení systému.**
- *Softvérové knižnice a systémy*
  - **Systémy a knižnice, ktoré je možné využiť.**

Témy (4)

- Extrakcia informácií
  - **Základné úlohy extrakcia a aké algoritmy a prostriedky sa dajú využiť pri extrakcii**
- Regulárne výrazy
  - **Spracovanie textu**
  - **Extrakcia metadát**
  - **Find**
  - **Replace**
  - **Split**

Témy (5): Súčasný internet

- Keďže sa venuje hlavne vyhľadávaniu informácií na internete, je potrebné sa venovať internetovým leaderom ako Google a Facebook ale aj iným typom textových a sociálnych informácií ako Delicious, Twitter (dnes už známy pod menom X) alebo Linkedin.

- Zároveň aj MapReduce architektúre, ktorá je vhodným (dnes už máme lepšie – Apache Spark) prístupom pre spracovanie rozsiahlych dát.