Projektové zadania

https://vi2026.ui.sav.sk/doku.php?id=projekty.pre.rok.2026

Projekty – otázky

- Kto programuje v Jave
- … v Python-e
- Lucene ? - http://lucene.apache.org/core/
- NLTK ? - http://nltk.org/
- Iba Java, Python, PIG?, alebo nástroje ako GATE, OpenNLP, Spotlight, Spark, Avro, Kaffka, iné streamovacie frameworky
- Kto ovláda na nejakej úrovni regexes?
- Sémantické vyhľadávanie?
- Grafové algoritmy?

Projekty

- Projekt je rozdelený do 2. častí
  - **1. polovica semestra**
    - Crawler
    - Full Text Search (primitívny indexer a searcher, vlastný, 2 rôzne metriky)
    - Extrakcia pomenovaných entít (v závislosti od projektu)
  - **2. polovica semestra**
    - Stiahnuté a vyextrahované entity spojené s inými veľkými zdrojmi (Wikipédia, Freebase?, ...)
    - Spustitelné nad distribuovanou architektúrou: Hadoop, Pig?, Spark, ...
    - Projekty budú spúšťané na UISAV klastri, ale iba mnou – nebudeme riskovať zahltenie klastra a pod. problémy
    - K dispozícii bude image v dockeri, kde sa to dá otestovať.
    - Už i vo windowse sa dá Hadoop jednoducho nasadiť

Čoho sa vyvarovať

- Zabudnite na databázu (nepoužívať)
  - **Sme na IR**
  - **Ak potrebujete nejaký zoznam, uložiť do text súboru alebo XML/JSON a pod. a natiahnuť do pamäte. Väčšie dáta treba indexovať**
- nepoužívať rar (kvôli linuxu)
  - **Zip**
- nepoužívať XPath alebo metódy na extrakciu podľa presnej štruktúry stránky pri webe.

Čo je dôležité

- !**Dáta, dáta a ešte raz dáta**!
  - **Treba riešiť hneď od začiatku**
  - **minimálne minimum 500MB+ optimum niekoľko GB**
  - **Crawler vlastný**
    - Nikdy nič nemazať
  - **Wikipédia cez 90GB textu – 21.3GB komprimované, Freebase 250GB - komprimované 22GB**
  - **optimum pracovať s dátami z Wikipedie (EN, SK) alebo Freebase**
  - **Môžu byť aj iné dáta ak je zaujímavý problém ale 500MB+ alebo iné dáta kde je rozsiahly počet záznamov (aspoň 1 milión)**
  - **Už na prvej konzultácii treba mať prezreté dáta a treba rozumieť ako ich idete spracovávať.**
  - **Rôzne Kaggle súťaže**

Čo je dôležité

- Vyhodnotenie
  - **Treba vyhodnotiť úspešnosť riešenia**
  - **Recall, precision, ...**
- Nie je dôležité aby to fungovalo na 100% - to nikdy nebude (ani googlu to nejde a má iné zdroje)
  - **Ide o to sa niečo naučiť a vyskúšať**

Wikipedia, Freebase, a iné (informácie ukryté v týchto zdrojoch)

- Slovenská Wikipedia - rozbalené 1.58GB
- Anglická Wikipedia - rozbalené okolo 90GB
  - Parsovanie
    - Title, redirect, anchor texts, links, abstract....
  - indexovanie a vyhľadávanie
  - vyhľadávanie v multimédiách
  - lematizácia
  - rozpoznávanie entít
  - vyhľadávanie podľa anchor textov liniek
  - query categorization
  - Entity search
  - Použitie siete/grafu prepojení (liniek) na výpočet podobností, PageRank ...
  - ďalšie nápady ...
- Spracovanie Freebase - okolo 250 GB

LinkedData – všetky projekty (minimálne s Wikipédiou)

- Hľadanie relácií
- Indexovanie a vyhľadávanie entít
  - **Textovo**
  - **Grafovo**
- https://lod-cloud.net/
- Treba si vziať časť dát
  - **DBLP**
  - **Wikipédia**
  - **Geo dáta**
  - **???**

Projekt: Vlastné nápady – všetci

- Stiahnutie stránok o futbalových kluboch
  - Futbalistoch
  - Manažéroch
- Stiahnutie stránok o hokejových kluboch
  - Hokejistoch
  - Manažéroch
- Kuchárske recepty
- ...
- ???
- Stiahnutie stránok o geo lokalitách
  - Nejaké zaujímavé fakty
  - ...