Sťahovanie dokumentov, spracovanie odkazov, tovrba bázy dokumentov

Vyhľadávanie informácií

Martin Šeleng

Literatúra

- http://en.wikipedia.org/wiki/Web_crawler
  - **Obsahuje dobrý prehľad s odkazmi na literatúru**
- Nový učebný text
  - **Kapitola 2: ZÍSKAVANIE DÁT ALEBO DOKUMENTOV**

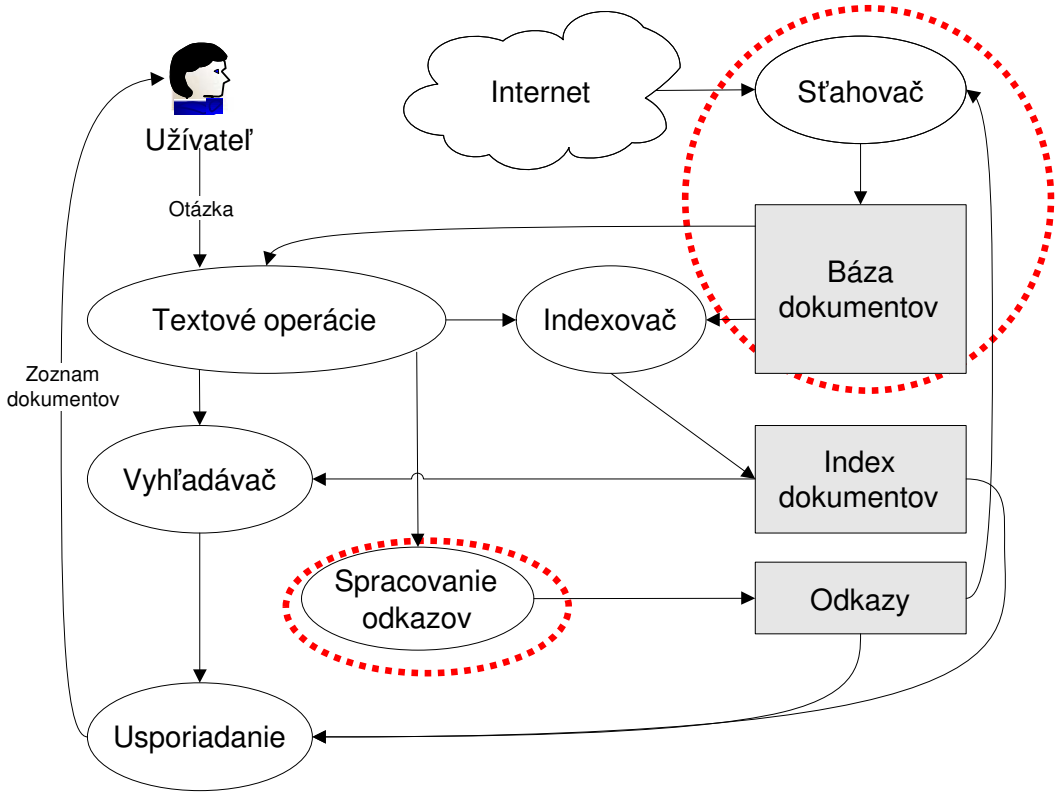
Architektúra

získavanie informácií

- stiahnutie dokumentov
- textové operácie
- indexovanie
- spracovanie odkazov

Vyhľadávanie

- formulácia dopytu a operácie na dopyte
- spracovanie dopytu
- vrátenie výsledku na používateľské rozhranie
- spätná väzba od používateľa

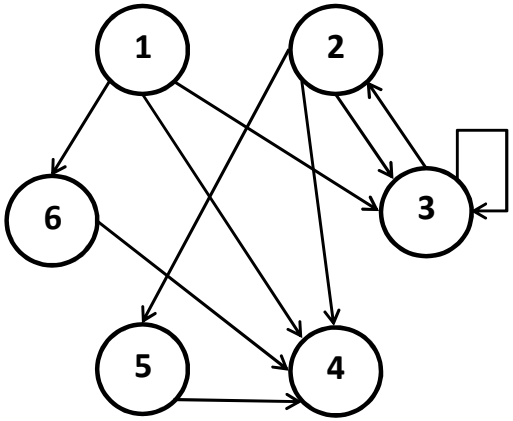


Sťahovač

- web crawler, Web spider, Web robot

- Začne z jedného alebo viac zdrojov (liniek),
- ukladá cache dokumentov alebo iné získané informácie,
- vyhľadáva linky v dokumentoch,
- ukladá informácie o linkách na ďalšie spracovanie do zásobníka,
- pokračuje nad ďalšou linkou (rekurzívne alebo vytiahne linku zo zásobníka)

Postup na príklade



Do hĺbky (Depth-first DFS) LIFO:

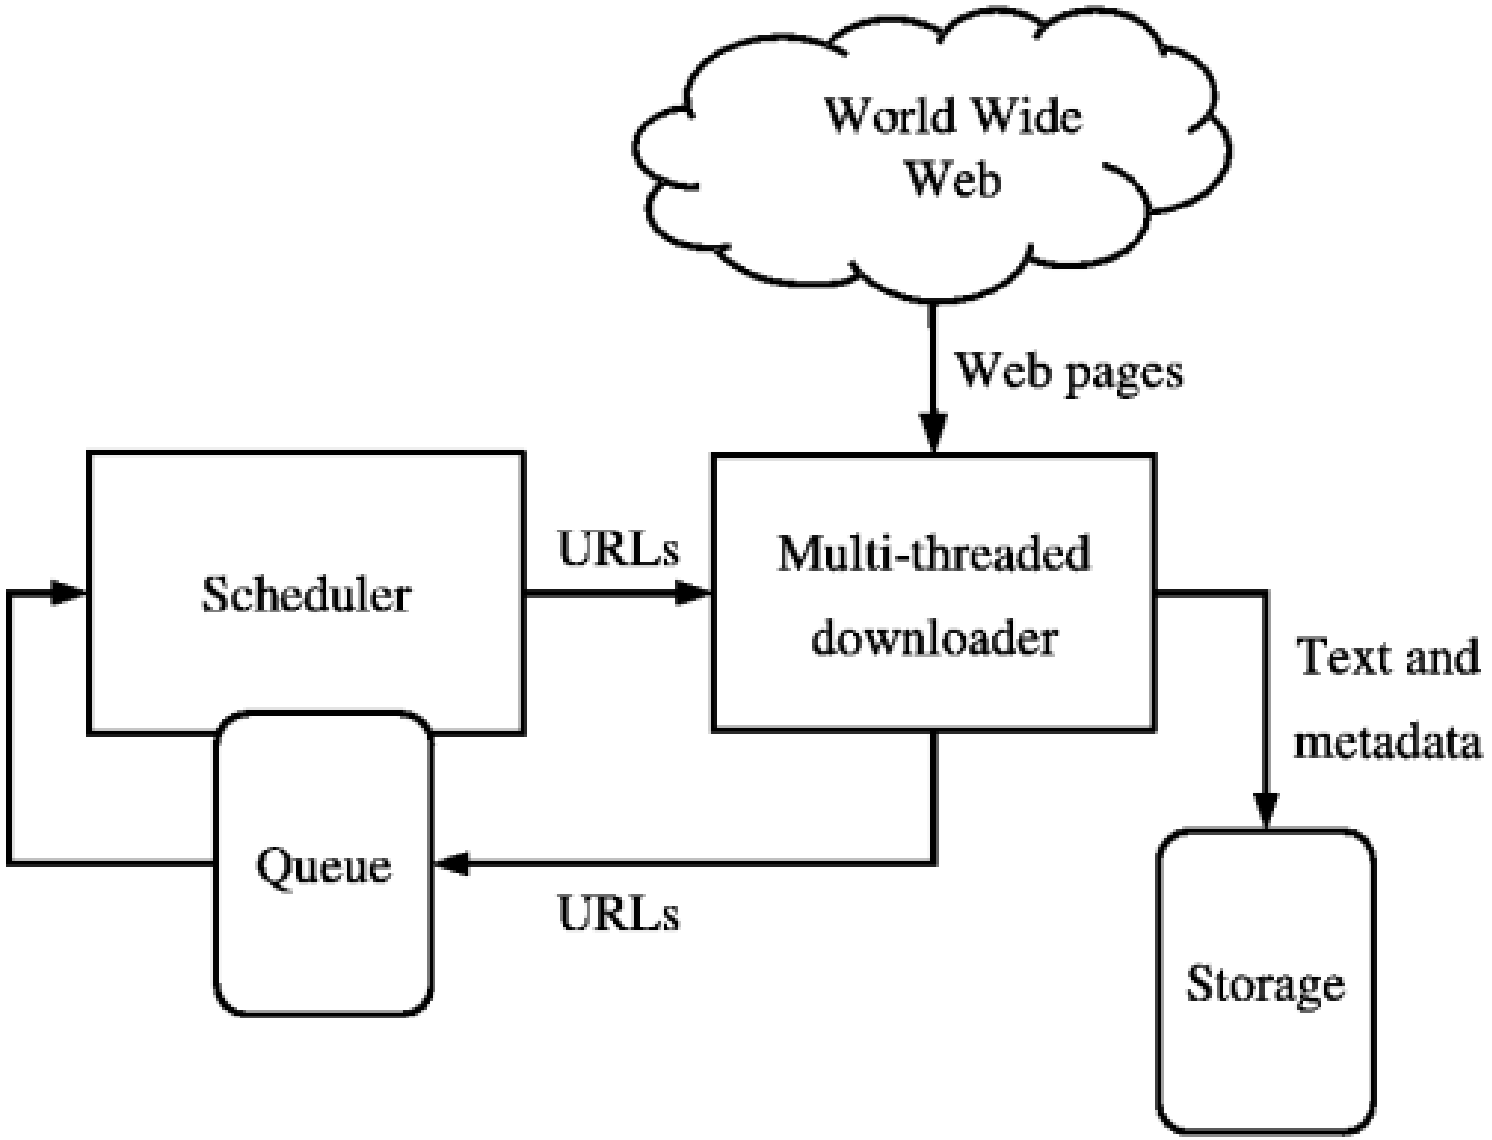
1 3 2 4 5 6

Do šírky (Breadth-first BFS) FIFO:

1 3 6 4 2 5

Číslo	Text Dokumentu (linky sú podčiarknuté na konci je číslo dokumentu kde ukazujú)
1	Vyhľadávanie informácií Informácie o predmete: • Výučba predmetu na: FIIT STU(3) • Zabezpečuje: Michal Laclavík(6), Martin Šeleng • Pracovisko: UISAV(4) miestnosť 312, 306
2	WIKT 2010 - 5th Workshop on Intelligent and Knowledge oriented Technologies Organizátori: • ÚI SAV(4), Bratislava • FIIT STU(3), Bratislava • CIT FEI, TU(5), Košice
3	Fakulta informatiky a informačných technológií PODUJATIA: • ProFIIT 2010 – finale 19. - 20. marca 2010, FIIT STU v Bratislave • WIKT 2010(2) Fakulta informatiky a informačných technológií STU v Bratislave Ilkovičova 3 842 16 Bratislava 4 fax: (02) 654 20 587 e-mail: info@fiit.stuba.sk web: www.fiit.stuba.sk(3) ---------- Generované redakčným systémom Buxus spoločnosti ui42, spol. s r.o.
4	Ústav informatiky SAV Riaditeľ: Doc. Ing. Ladislav Hluchý, PhD. Adresa: Dúbravská cesta 9, 845 07 Bratislava, SR Sekretariát: Tel./Fax: 02 5477 1004 e-mail: sekr.ui@savba.sk
5	CIT - Centrum pre informačné technológie CIT je spoločné pracovisko Ústavu informatiky Slovenskej akadémie vied(4) v Bratislave a Technickej univerzity v Košiciach, zriadené k 1.2.2005. Pracovisko sídli na ulici Boženy Nemcovej 3 v Košiciach. CIT FEI, TU v Košiciach, Letná 9, 042 00 Košice, Tel./fax: +421 55 602 4128
6	Michal Laclavik Welcome ! Currently I am working as researcher at Institute of Informatics SAS(4) Phone: +421-2-59411256 Email: michal.laclavik@savba.sk ICQ #: 46344728

Architektúra sťahovača



Typy sťahovačov

- Harvest
  - Path-ascending crawlers
    - Efektívny na izolované zdroje (na ktoré neukazujú žiadne linky)
  - Deep web (formuláre)
- Focused/Topical Crawling
  - Iba .jp doménu
  - Stiahni stránky o bejzbale
  - Stiahni stránky s vysokým PageRank-om (https://en.wikipedia.org/wiki/PageRank)
    - Toto viedlo k topic crawlerom - napr. stránky iba o covide, ...
  - Anchor text liniek
  - Rozhodnutie pred sťahovaním linky
  - Po stiahnutí, klasifikácia
    - Netreba indexovať, ukladať, to čo nechceme
- Academic Focused Crawler
  - CiteSeerX https://en.wikipedia.org/wiki/CiteSeerX
  - Google Scholar https://en.wikipedia.org/wiki/Google_Scholar
  - Microsoft Academic Search https://en.wikipedia.org/wiki/Microsoft_Academic_Search
- Semantic Focused Crawler
  - Focused crawlers založené na ontológiách
    - Snaží sa priamo stránky mapovať na ontológiu, alebo filtrovať irelevantné webstránky vzhľadom na topic
  - Metadata Abstraction Focused Crawlers
    - Navyše ešte abstrahujú a anotujú metadáta webstránky
  - Iné Focused Crawlers
    - Nepoužívajú ani ontológie ani anotáciu metadát

Stratégie

- Do hĺbky
- Do šírky
- výpočet čiastočného PageRank a sťahovanie stránky s najväčším PageRank
- výpočet OPIC (On-line Page Importance Computation) https://en.wikipedia.org/wiki/Web_crawler#Crawling_policy
- Obmedzenia
  - **maximálny počet stiahnutých stránok**
  - **maximálna hĺbka vnorenia od počiatočných stránok**
  - **maximálny čas sťahovania**
  - **Typ dokumentov (HTML, doc, PDF, obrázky, videá)**
  - **Obmedzenie na domény**
  - **Obmedzenie URL pomocou regulárnych výrazov**
  - **Sťahovanie iba statických dokumentov, vynechanie dynamického obsahu**

Crawling policies

- Problém sťahovačov v prostredí internetu
  - **Objem dát**
    - Priorita
  - **Veľmi rýchlo meniaci sa obsah**
    - Znovu sťahovanie
  - **Generovanie dynamických stránok**
    - Rovnaký obsah cez rôzne URL
    - Zoraďovanie, tlač, poslať emailom, ...
    - Story www.sav.sk indexing ...
- Znovu sťahovanie
- Problémy s dynamicky generovanými stránkami
  - **Problém – zahltenie serverov**
  - **Riešenie – distribuované sťahovanie**

Policy - taktiky

- *selection policy* (výber)
  - **Ktoré stránky sťahovať**
- *re-visit policy* (znovu navštívenie)
  - **Kedy znovu navštíviť stránky**
- *politeness policy* (zdvorilostné taktiky)
  - **Zabrániť zahlteniu stránok**
- *parallelization policy (distribučné taktiky)*
  - **Ako organizovať distribuované sťahovanie**

Selection Policy

- breadth-first, Do šírky
  - Asi najpoužívanejšie
  - Stránky s vysokým PageRank sa nájdu skoro
  - Dá sa vylepšiť čiastočným PageRank
- backlink-count
  - Počet liniek ukazujúcich na stránku
- Čiastočný Pagerank
  - Vypočítaný z doteraz stiahnutých liniek
- OPIC (On-line Page Importance Computation)
  - Každá stránka má na začiatku určité množstvo peňazí, ktoré je distribuované rovnomerne stránkam na ktoré ukazuje

Obmedzenia

- Typ dokumentov (MIME Type)
  - **HEAD Request, GET (podobné, len tu sú aj dáta)**
  - **Podľa prípony (tu riskujeme, že môže vynechať dôležité info)**
- Domény
- Regulárne výrazy
- Deep web (?, &, …) (formuláre)

Deep Web

- Niekedy sa tu zahŕňajú aj všetky dynamické stránky ?& …
- Niekedy len tie ktoré sú prístupne cez vyhľadávací dopyt na stránke
  - **Žiadne linky neukazujú na tieto zdroje**
  - **Sitemaps (Podobné ako robots.txt)**
  - **mod_oai (modul do apache) – dnes už veľmi nepodporovaný**
  - **Vždy musí povoliť, zverejniť vlastník stránky**
  - **Používa sa pri platených službách**

Re-visit policy

- Uniform
- Proportional

- Najlepšia stratégia
  - **Proporčná + ignorovanie príliš rýchlo meniacich sa stránok**

Politeness policy

- **Sieťové zdroje (Network resources)**, keďže sťahovače potrebujú slušnú prenosovú rýchlosť a operujú s vysokým stupňom paralelizmu počas dlhej doby.
- **Preťaženie servera (Server overload)**, špeciálne keď frekvencia prístupov k serveru je príliš vysoká.
- **Zle napísané sťahovače**, ktoré vedia zhodiť server/smerovače, a ktoré nevedia spracovať stránky, ktoré stiahnu.
- **Personálne sťahovače (Personal crawlers)**, ktoré keď sú nasadené mnohými používateľmi, môžu narušiť siete/servery.

Politeness policy

- Na jednu doménu(site) pristupovať v intervale
  - **60, 15, 10 sekúnd**
  - **Dnes je optimálne aj 1 s**
- User-agent HTTP requestu
- Slušnosť káže identifikovať sa
- Crawler trap (Spider trap) – slušné crawleri a slušné stránky so súborom robots.txt nemajú problém (v robots.txt je napísané kam neísť)
  - **Vytvorenie nekonečnej štruktúry adresárov, ako napr. http://example.com/bar/foo/bar/foo/bar/foo/bar/...**
  - **Dynamické stránky, ktoré produkujú neobmedzený počet dokumentov pre webový sťahovač, ktoré musí spracovávať. Príkladom sú: kalendáre a algoritmicky generovaná language poetry https://en.wikipedia.org/wiki/Language_poetry.**
  - **Dokumenty obsahujúce veľa znakov, ktoré vedia zhodiť lexikálne analyzéry spracuvajúce daný dokument.**
  - **Dokumenty so session-id‘s založené na požadovaných cookies.**
- Sťahovače sa často identifikujú ako web browsery (Mozilla, IE)

Parallelization policy

- Dynamic assignment
  - **Centrálny server rozdeľuje load, URLs**
  - **A small crawler configuration, in which there is a central DNS resolver and central queues per Web site, and distributed downloaders.**
  - **A large crawler configuration, in which the DNS resolver and the queues are also distributed.**
- Static assignment
  - **Uzly sa informuju o sťahovanych URL (sídlach, sites)**
  - **Hash URL websites**

Problém sťahovania rovnakých zdrojov

- URL normalization

- Sťahovač ktorý rozozná či sa stránka dostatočne líši a podľa toho sa rozhodne
  - **Ide o ignorovanie stránok s rovnakým obsahom iba zmena v zoradení, print, email ...**

Báza dát

- Cache verzie súborov
- Sťahovanie a ukladanie súborov len do určitej veľkosti
- Cache PDF, Word môže byť len text
- Zipovanie dokumentov, keďže sú riedke
- Prídavné súbory (CSS, images)
  - **Podľa potreby**
  - **Zmena referencií na externé objekty**

Spracovanie odkazov

- Linka
- Text odkazu
- Text odkazu – súčasť dokumentu pre indexovanie
- < href=http://nieco/stranka/>Text odkazu
- **Text odkazu** sa prida k dokumentu linky
- V linkách sa často vyskytujú Named Entity
  - **Použiť v projekte!!!**
  - **Posťahovať a zistiť štatistiku entít**
    - Organizácie
    - Ľudia
    - Udalosti
    - Časové značky
    - ...

Spracovanie URL

- Tokenizácia cez _ alebo NazovDokumentu
- Tiež /
- Osobitne doména