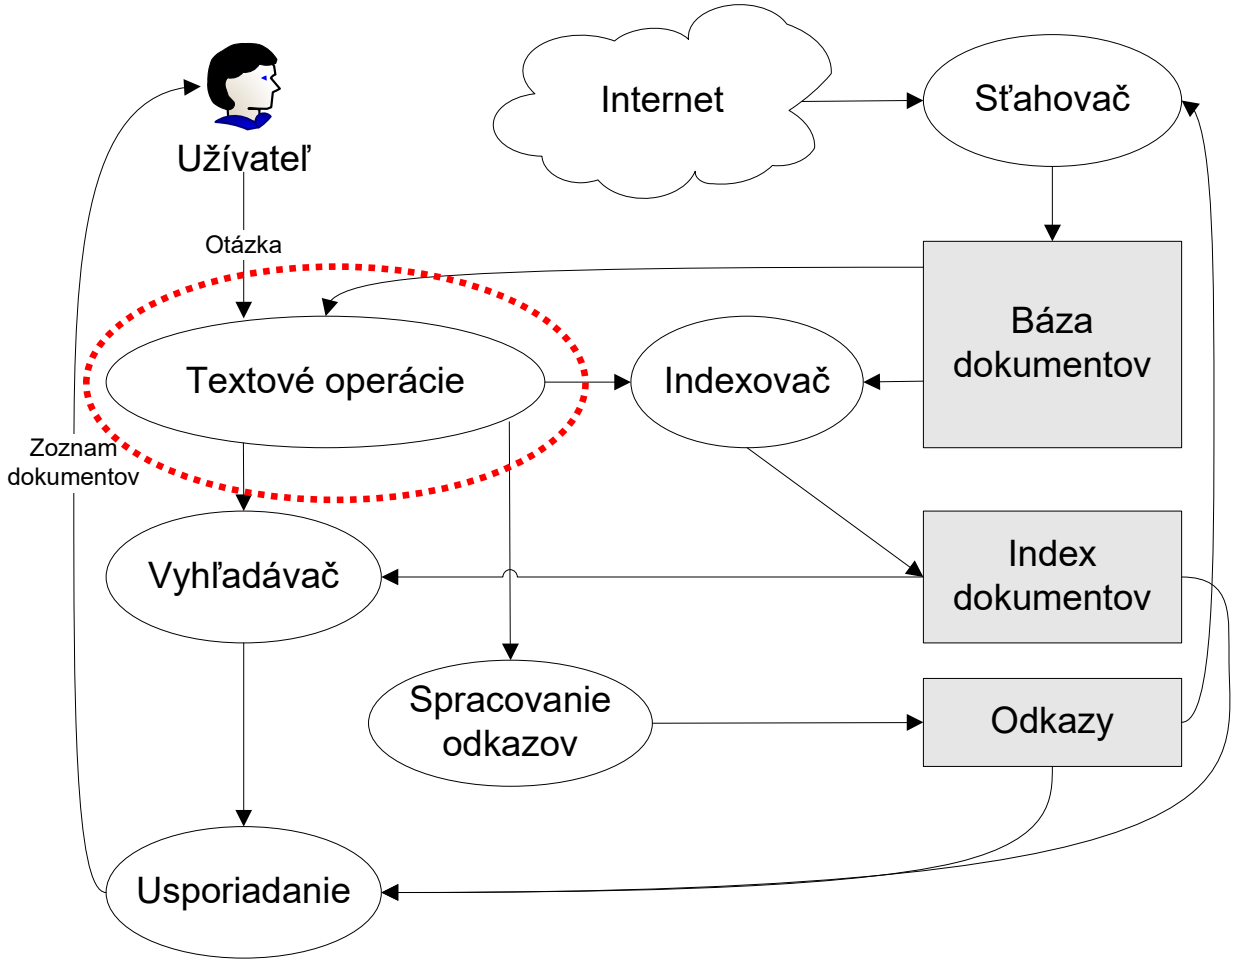
Textové operácie

Vyhľadávanie informácií

Martin Šeleng

Architektúra



Hlavné témy

- Konverzia na text
- Segmentácia
- Tokenizácia
  - **Detekcia objektov**
  - **URL**
  - **Čísla**
- Konverzia tokenov (značiek) na pojmy (termy)
  - **Lematizácia (nájdenie základného tvaru slova)**
  - **Stemming (nájdenie kmeňu slova – niekedy nesprávne označeného ako koreň slova)**
  - **Stop words**
  - **Dátum jednotný tvar**

Literatúra

- Nový učebný text
  - **Kapitola 3: ANALÝZA TEXTU, TEXTOVÉ OPERÁCIE**

Konverzia na text

- HTML: NekoHTML
  - http://nekohtml.sourceforge.net/
- DOC: Dokumenty MS Word - Apache POI.
  - http://poi.apache.org/
- PDF: OS Linux - pdftotext. Java – PDFBox
  - http://pdfbox.apache.org/
- Emaily: formát eml, mail server formát, Thunderbird (okrem MS Outlook) knižnica JavaMail.
  - http://www.oracle.com/technetwork/java/javamail/index.html https://javaee.github.io/javamail/ **(už nevyvíjané)**
- Apache Tika
  - **Jednotné API**
  - https://tika.apache.org/

Segmentácia

- Hlavička stránky,
- päta stránky,
- navigácia a menu,
- hlavný informačný segment stránky.

- Vety,
- paragrafy,
- odrážky,
- kapitoly s nadpisom.

- Hlavičky alebo segmenty reprezentujúce entity,
- Tabuľky, kde jednotlivé riadky reprezentujú entity a jednotlivé stĺpce ich vlastnosti.

Segmentácia emailov

- Hlavička emailu,
- text emailu,
- citovaný text emailu na ktorý sa odpovedá alebo preposiela,
- prílohy,
- signatúra.

Segmentácia – metódy

- *Štatistické metódy*: počet pojmov, liniek v pomere k inému textu v segmente napríklad na identifikáciu navigácie. Porovnanie počtu rovnakých slov alebo sekvencií vo webstránkach z toho istého sídla za účelom identifikácie hlavičky, navigácie a päty stránky.
- *Metódy strojového učenia:* trénovanie modelu identifikácie segmentov na príkladoch negatívnych a pozitívnych vzorov pri definovaní jednotlivých vlastností (features), ktoré si je potrebné všímať. Tieto vlastnosti môžu byť napríklad výskyt liniek, výskyt paragrafov (napríklad definovaný ako prázdny riadok v čistom texte), výskyt veľkých písmen a podobne.
- *Použitie vzorov:* napríklad aplikovanie regulárnych výrazov alebo tvorba stromov, sietí a grafov vychádzajúc zo štruktúry textu.
- *Vizuálne metódy:* Na web stránkach je hlavný informačný segment väčšinou bunka tabuľky s najväčšou šírkou, tu je potrebné použiť parsovanie a akoby vizualizáciu HTML tak ako by dokument videl užívateľ za účelom zistenia skutočného hlavného informačného segmentu.

Tokenizácia

- Token
  - **(Garabík et al., 2004):** ***Token je arbitrárna jednotka textu, ktorá rozširuje lingvistický význam pojmu slovo. Za token sa v automatickej segmentácii textu považuje akýkoľvek reťazec znakov medzi dvoma medzerami (whitespace), aj jednotlivé znaky interpunkcie, ktoré nemusia byť oddelené medzerou od predchádzajúceho alebo nasledujúceho tokenu. Text sa teda z formálneho hľadiska skladá z tokenov a medzier (whitespace).***
- https://korpus.juls.savba.sk/attachments/publications/2004-garabik-gianitsova-horak-simkova-tokenizacia.pdf

Lexikálne analyzátory (1)

- Proces rozdelenia textu na základné značky (tokeny)
- Lexery (lexikálne analyzátory) – systémy vykonávajúce lexikálnu analýzu
  - **aj v predspracovaní programu pre kompiláciu**
  - **Aj v IR**
    - Generované značky (tokens) priradzujú jednotlivým častiam textu dodatočnú informáciu o ich lexikálnom význame.

- Lexikálna značka
  - **[cesta ~ WORD];**
  - **[9 ~NUMBER];**
  - **[, ~ COLON];**
  - **[1.2.2005 ~ DATE];**
  - **[www.fiit.stuba.sk ~ LINK]**

- CIT je ... pracovisko ... zriadené k 1.2.2005
- [cit ~ WORD]; [je ~ WORD]; [pracovisko ~ WORD]; [zriadené ~ WORD]; [k ~ WORD]; [1.2.2005 ~ DATE]

Lexikálne analyzátory (2)

- Úprava kódovania
- Lowercase
- Spracovanie diakritiky
- Lexer
  - https://en.wikipedia.org/wiki/Lexical_analysis
  - https://github.com/westes/flex
  - https://www.jflex.de/

Konverzia značiek na pojmy

- Konverziu (napríklad prevedenie slova na základný tvar, prevedenie čísla alebo dátumu na jednotný formát),
- vynechanie značky (stop slová, bodky, čiarky),
- spracovanie zložených slov (compound words), je potrebné sa rozhodnúť v závislosti od aplikácie ako budú tieto slová indexované, či ako jeden pojem alebo viac pojmov,
- alebo vloženie slov (reprezentácia slova pomocou synoným, napr. notebook, laptop)
- oprava preklepov (spelling correction).
  - **nie nad dokumentami (časovo náročná, ale dnes sa už asi robí i nad dokumentami!!!)**
  - **v aplikáciách má zmysel hlavne pri interakcii s používateľom.**
  - **nevyhnutnou súčasťou dnešných systémov na strane užívateľa pri zadávaní textového dopytu**
- spracovanie dokumentov ktoré neobsahujú diakritiku
  - **SMS, chat, emaily**

Tokenizácia

- Rozdelenie textu na tokeny značky
  - **Z tokenov sa odvodia termy ktoré sa budú indexovať**
  - **Niektoré tokeny sa vynechajú (bodky, čiarky, stop slová a podobne)**
  - **Niektoré sa transformujú (základny tvar, jednotný tvar čísla, ...)**
- Zlé rozdelenie znamená že slovo/term značka z textu nebude v indexe
- Dátumy v rôznom tvare
  - **Možno zjednotiť na rovnaký formát – zoraďovanie vyhľadávanie**
- Diakritika, rôzne tvary slov ...
- Každý jazyk iné pravidlá
  - **Napr. čínština ťažká tokenizácia – nemajú medzery medzi slovami**
- Tokenizácia = časť reprezentácie textu
  - **Dokument nie sú len slová alebo termy**
  - **Myšlienky, nápady, príbehy, ... degradujeme na termy**
  - **Zatiaľ najlepšie čo sa vymyslelo ale nepokrýva úplne dokument**

Lucene Tokenizácia (1)

- **Sample text: XY&Z Corporation – xyz@example.com**
- WitespaceAnalyzer (WhitespaceTokenizer) – ponechá všetko, len rozdelí cez medzery
  - **[XY&Z] [Corporation] [–] [xyz@example.com]**
- SimpleAnalyzer (LetterTokenizer, LowerCaseFilter) – rozdelí text cez nie znakové značky (ponechá len písmená abecedy)
  - **[xy] [z] [corporation] [xyz] [example] [com]**
- StopAnalyzer (LetterTokenizer, LowerCaseFilter, StopFilter) – rozdelí text cez nie znakové značky a odstráni stop slová, nerozozná URL a email
  - **[xy] [z] [corporation] [xyz] [example] [com]**
- StandardAnalyzer (StandardTokenizer, StandardFilter, LowercaseFilter, StopFilter) - rozozná URL a emailové adresy (do verzie 3.0 – dnes je to ClassicAnalyzer, alebo radšej UAX29URLEmailAnalyzer)
  - **[xy&z] [corporation] [xyz@example.com]**
- EnglishAnalyzer (StandardTokenizer, StandardFilter, EnglishPossessiveFilter, LowerCaseFilter, StopFilter, PorterStemFilter)
- Custom Analyzer – je na vás čo si tam dáte
- Rôzne analyzéry pre rôzne fieldy (PerFieldAnalyzerWrapper)

Lucene Tokenizácia (2)

- CIT FEI, TU v Košiciach, Letná 9, 042 00 Košice, Tel./fax: +421 55 602 4128
- *WhiteSpaceAnalyzer*
  - [CIT ~ word] [FEI, ~ word] [TU ~ word] [v ~ word] [Košiciach, ~ word] [Letná ~ word] [9, ~ word] [042 ~ word] [00 ~ word] [Košice, ~ word] [Tel./fax: ~ word] [+421 ~ word] [55 ~ word] [602 ~ word] [4128 ~ word]
- *SimpleAnalyzer*
  - [cit ~ word][fei ~ word][tu ~ word][v ~ word][košiciach ~ word][letná ~ word][košice ~ word][tel ~ word][fax ~ word]
- *StandardAnalyzer (ClassicAnalyzer)*
  - [cit ~ <ALPHANUM>] [fei ~ <ALPHANUM>] [košiciach ~ <ALPHANUM>] [letná ~ <ALPHANUM>] [9 ~ <NUM>] [042 ~ <NUM>] [00 ~ <NUM>] [košice ~ <ALPHANUM>] [tel ~ <ALPHANUM>] [fax ~ <ALPHANUM>] [421 ~ <NUM>] [55 ~ <NUM>] [602 ~ <NUM>] [4128 ~ <NUM>]
- *StandardAnalyzer* aplikujeme na celý dokument 5, kde je napríklad aj dátum:
  - CIT ..., zriadené k 1.2.2005. .....
  - [1.2.2005 ~ <HOST>]
- Alebo ak aplikujeme na dokument 6:
  - Phone: 421-2-59411256
  - Email: michal.laclavik@savba.sk
  - ICQ #: 46344728.
  - [phone ~ <ALPHANUM>] [421-2-59411256 ~ <NUM>] [email ~ <ALPHANUM>] [michal.laclavik@savba.sk ~ <EMAIL>] [icq ~ <ALPHANUM>] [46344728 ~ <NUM>]

Lucene Tokenizácia (3)

Číslo	**Text Dokumentu** (linky sú podčiarknuté na konci je číslo dokumentu kde ukazujú)
1	Vyhľadávanie informácií Informácie o predmete: • Výučba predmetu na: FIIT STU(3) • Zabezpečuje: Michal Laclavík(6), Martin Šeleng • Pracovisko: UISAV(4) miestnosť 312, 306
2	WIKT 2010 - 5th Workshop on Intelligent and Knowledge oriented Technologies Organizátori: • ÚI SAV(4), Bratislava • FIIT STU(3), Bratislava • CIT FEI, TU(5), Košice
3	Fakulta informatiky a informačných technológií PODUJATIA: • ProFIIT 2010 – finale 19. - 20. marca 2010, FIIT STU v Bratislave • WIKT 2010(2) Fakulta informatiky a informačných technológií STU v Bratislave Ilkovičova 3 842 16 Bratislava 4 fax: (02) 654 20 587 e-mail: info@fiit.stuba.sk web: www.fiit.stuba.sk(3) ---------- Generované redakčným systémom Buxus spoločnosti ui42, spol. s r.o.
4	Ústav informatiky SAV Riaditeľ: Doc. Ing. Ladislav Hluchý, PhD. Adresa: Dúbravská cesta 9, 845 07 Bratislava, SR Sekretariát: Tel./Fax: 02 5477 1004 e-mail: sekr.ui@savba.sk
5	CIT - Centrum pre informačné technológie CIT je spoločné pracovisko Ústavu informatiky Slovenskej akadémie vied(4) v Bratislave a Technickej univerzity v Košiciach, zriadené k 1.2.2005. Pracovisko sídli na ulici Boženy Nemcovej 3 v Košiciach. CIT FEI, TU v Košiciach, Letná 9, 042 00 Košice, Tel./fax: +421 55 602 4128
6	Michal Laclavik Welcome ! Currently I am working as researcher at Institute of Informatics SAS(4) Phone: +421-2-59411256 Email: michal.laclavik@savba.sk ICQ #: 46344728

Identifikácia jazyka

- štatistických prístupoch
  - **Počet slov zo slovníka**
- využívajúc techniku *n*-gramov
- monte carlo prístup https://pdfs.semanticscholar.org/9078/328e6b48c4eda12d26bdc950744a874f2c8e.pdf
  - **viac ako 50 znakov**
- kombináciu n-gram a markovovských modelov
  - **NALIT z NAZOU projektu**
- strojové učenie
  - **https://machinelearning.apple.com/research/language-identification-from-very-short-strings**

Stop slová

- Slovenčina
  - **a, o, alebo, ale, sú, táto**
- Angličtina
  - **A, the, and, of**
- N – najčastejšie sa vyskytujúcich slov
  - **Ak mám kolekciu dokumentov o poistení, tak i slovo poistenie je v podstate stop slovo, lebo sa nachádza prakticky v každom dokumente a to niekoľko krát!!! (ale je to vždy na aplikácii a probléme, že ako je definované stop slovo!!!)**

Základný tvar slov

- Zahrnutie rôznych morfologických tvarov slov
  - fishing, fished, fish, fisher = **fish**
- Lematizácia – základný tvar slova
  - Lema sa zvyčajne definuje ako “slovníkový” tvar tokenu
- Stemming – kmeň slova
  - Kmeň slova – základná časť slova, ktorá sa v rozličných tvaroch toho istého slova zvyčajne nemení a ku ktorej sa pripájajú jednotlivé pádové (pri menách) alebo osobné prípony (pri slovesách)
    - oteck-o, oteck-a, oteck-ovi; maľuje-m, maľuje-te, maľuje-me (oteck je kmeň slova)
  - Koreň slova – je tá časť slova, ktorá je u všetkých príbuzných slov rovnaká
    - žen-a, o-žen-iť, žen-ský (žen je koreň slova)

Lematizácia

- Väčšinou na slovníkovom princípe za pomoci morfologického slovníka
- Nevýhody
  - **Nedá sa získať tvar pre slová ktoré nie sú v slovníku**
  - **„mier“ môže byť morfologickým variantom významovo rozličných slov: „mier“, „miera“ „mierit”“.**
- WordNet https://wordnet.princeton.edu/ – výkladový slovník, obsahuje aj morfologické varianty – angličtina
- a-spell a iné, http://www.sk-spell.sk.cx/
- Machine learning
- Deep learning

Stemming

- Proces redukcie na kmeň(koreň podľa potreby a definície) slova alebo základný tvar, rovnaký pre všetky morfologické tvary
- Problémy, metriky
  - **pre-stemmovanie**
  - **pod-stemmovanie**
- Angličtina – Porterov algoritmus http://snowball.tartarus.org/algorithms/porter/stemmer.html
- Google
  - **Od 2003 pre angličtinu**

Stemming algoritmy

- brute force
- orezávajúce sufixy
  - **if the word ends in 'ed', remove the 'ed'**
  - **if the word ends in 'ing', remove the 'ing'**
  - **if the word ends in 'ly', remove the 'ly,**
- POS tagging – slovné druhy a aplikácia pravidiel
  - **Je dobré použiť nejaký POS tagging aj vo vašich projektoch**
- stochastické algoritmy vytvárajúce pravdepodobnostný model na základe známych relácií medzi koreňmi a morfologickými tvarmi slov.
- Zložitosť záleží od jazyka
  - **Angličtina jednoduchšie ale má slová ako run, ran**
  - **Slovenčina zložité**

Lematizácia v Slovenčine

- Google – podpora tvarov v slovenčine od 2007.
- Kmeň(koreň) slova „rada“ je „rad“ pričom tento kmeň(koreň) zahŕňa pri uvažovaní bez diakritiky nasledovné slová:
  - **rada – podstatné meno, orgán**
  - **rád – podstatné meno, vyznamenanie**
  - **rád – sloveso**
  - **rad – podstatné meno, zoradenie**
  - **rada – podstatné meno, ponaučenie.**

Problém diakritiky

- Rôzne kódovania
  - **win-1250, ISO-8859-2 alebo UTF-8**
  - **HTML značky začínajúce „&#“.**
- Emaily – často bez diakritiky

- Forma s.r.o. http://www.forma.sk/
  - **Tvorí jazykové knižnice pre Microsoft**
  - **Spellcheck atd.**
  - **www.zbierka.sk**

Stemming slovenčina

- Korpus.sk
- Slovenský národný korpus (SNK) je elektronická databáza slovenského jazyka zahŕňajúca široké spektrum jazykových štýlov, žánrov a vecných oblastí, obsahujúca prídavné jazykovedné informácie a výkonný vyhľadávací systém.

- Ručne naplnené dáta o niektorých slovných druhoch a tvaroch

JÚLŠ lematizer

- Slovníkový princíp
- Koncovky slov
- Levenshteinové operácie (viď nižšie)

- Beta verzia lematizátora
  - **Dnes, neznámy stav**

- Cieľ iný ak v IR

Tvaroslovník

- UPJŠ
- Najdlhší koniec slov
- Slovník slovenského jazyka – oskenovaný
  - **nie celkom legálny prístup**

- Keď sa vypne overovanie v slovníku môže slúžiť aj ako stemmer

Prečo treba algoritmický stemmer

- „Róbert Fico“, „Róbertovi Ficovi “, „Robertom Ficom“
  - **Rôzne výsledky**
- Slová ktoré nie sú v slovníku
- Názvy miest a obcí, priezviská a mená

- Stempel - poľština
  - **Elasticsearch https://www.elastic.co/guide/en/elasticsearch/plugins/current/analysis-stempel.html)**
  - **Morfeusz http://morfeusz.sgjp.pl/**
  - **Kombinácia slovníka, kvôli štatistike**
- Egothor algoritmus – čeština
  - **https://egothor.sourceforge.net/**

Levenshteinove operácie

- Vloženie
- Vymazanie
- Nahradenie

- Ucho, uši
- Pes, psík

- Použitie v Lematizácii ale aj podobnosť slov, spellcheck
- Podobnosť podľa kosínusovej vzdialenosti
- Prípadne úprava odporučenie dopytu pri preklepoch

- SimMetrics https://github.com/Simmetrics/simmetrics (v Jave rôzne typy metrík podobnosti, dnes už nevyvíjané)

Part of Speach Tagging

- POS sa využíva pri spracovaní textu – identifikácia slovných druhov (sloveso, podstatné meno, prídavné meno, ...)
- Identifikácia objektov
- Lematizácia
- Identifikácia termov zložených z viac slov
- V slovenčine neexistoval (už je napr. http://morpholyzer.fiit.stuba.sk:8080/PosTagger/index.jsp - mŕtve)
  - **Veľa vecí je priamo na FIIT: http://text.fiit.stuba.sk/ - mŕtve**
  - **Lematizér a stemmer**
  - **POS tagger**
- Angličtina QTag library https://dl.acm.org/doi/10.1145/1297144.1297184